Recuperación de opiniones de Steam — Etapa 1

Asignatura: Procesamiento de Lenguaje Natural. **Equipo:** Kevin, Ángel y Erick.

Estado: evaluación ejecutada. **Juicios de relevancia:** revisados por el equipo.

1. Objetivo y corpus

El sistema busca opiniones que discuten un aspecto o experiencia expresados como consulta libre. Utiliza representación en espacio vectorial y similitud coseno; el rating binario de Steam se conserva sólo como metadato.

Indicador	Resultado
Documentos crudos y normalizados	492 / 492
Videojuegos	12
Fuente	API pública de reseñas de Steam
Valoraciones	0: 237; 1: 255
Período reseñas	2019-08-23 a 2026-10-11
Muestreo	12 videojuegos x 41 reseñas; idiomas latam y spanish

2. Normalización y representaciones VSM

Se parte de los textos normalizados mediante spaCy (POS, eliminación selectiva de artículos, preposiciones, conjunciones y pronombres, lematización y limpieza). Para consultas nuevas, el programa exige exactamente el mismo normalizador; no aplica un proceso alternativo silencioso.

Se crearon 12 configuraciones: corpus [reseña / nombre del juego + reseña] × características [unigrama / bigrama] × ponderación [frecuencia / binaria / TF-IDF]. Cada configuración conserva vectorizador y matriz dispersa para el cálculo de coseno.

3. Consultas y juicios de relevancia

El benchmark contiene 15 consultas (5 fáciles, 5 medias y 5 difíciles) y 180 juicios iniciales (12 por consulta, relevancias 1 o 2). Los IDs se corresponden con review_id del corpus congelado. No se incluyen relevancias 0 en qrels.

ID	Nivel	Consulta
Q01	1	errores, bugs y fallos técnicos
Q02	1	mala optimización y bajos FPS
Q03	1	opiniones sobre la historia y los personajes
Q04	1	música y banda sonora del juego
Q05	1	jugar con amigos en modo cooperativo
Q06	2	la partida sufre tirones y se ralentiza
Q07	2	el combate es desafiante para principiantes
Q08	2	las mismas tareas terminan cansando
Q09	2	vale lo que cuesta pagar por él
Q10	2	descubrir secretos explorando el mundo
Q11	3	mi equipo no mantiene una experiencia fluida
Q12	3	una narrativa que consigue involucrarme emocionalmente

ID	Nivel	Consulta
Q13	3	la aventura mejora cuando no estás solo
Q14	3	al inicio la experiencia exige paciencia para dominarla
Q15	3	la ambientación deslumbra por su belleza

4. Evaluación cuantitativa

Configuración: review, unigram, tfidf. P@10, R@10 y F1@10 consideran relevantes grados 1 y 2; MRR utiliza el primer relevante del ranking completo; nDCG@10 utiliza grados 1 y 2 con ganancias exponenciales.

Nivel	P@10	R@10	F1@10	MRR	nDCG@10
1	0.440	0.367	0.400	0.695	0.410
2	0.240	0.200	0.218	0.567	0.259
3	0.140	0.117	0.127	0.512	0.153
overall	0.273	0.228	0.248	0.591	0.274

5. Análisis de casos: mejores y peores consultas

Cinco con mejor desempeño

Consulta	P@10	nDCG@10
Q01	0.600	0.592
Q03	0.400	0.577
Q09	0.400	0.429
Q02	0.500	0.406
Q08	0.200	0.393

Cinco con menor desempeño

Consulta	P@10	nDCG@10
Q11	0.000	0.000
Q13	0.000	0.000
Q06	0.100	0.104
Q07	0.100	0.104
Q12	0.200	0.177

Q01: relevantes omitidos 6; resultados sin relevancia positiva anotada en top-10: 4. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q03: relevantes omitidos 8; resultados sin relevancia positiva anotada en top-10: 6. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q09: relevantes omitidos 8; resultados sin relevancia positiva anotada en top-10: 6. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q02: relevantes omitidos 7; resultados sin relevancia positiva anotada en top-10: 5. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q08: relevantes omitidos 10; resultados sin relevancia positiva anotada en top-10: 8. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q11: relevantes omitidos 12; resultados sin relevancia positiva anotada en top-10: 10. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q13: relevantes omitidos 12; resultados sin relevancia positiva anotada en top-10: 10. Hipótesis: Posible competencia de términos frecuentes, longitud de reseñas o ponderación VSM; revisar posiciones.

Q06: relevantes omitidos 11; resultados sin relevancia positiva anotada en top-10: 9. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q07: relevantes omitidos 11; resultados sin relevancia positiva anotada en top-10: 9. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Q12: relevantes omitidos 10; resultados sin relevancia positiva anotada en top-10: 8. Hipótesis: Posible desajuste léxico o sinonimia: documento relevante omitido comparte pocos términos con la consulta.

Guía de interpretación: examinar falsos positivos y relevantes omitidos por sinónimos, escaso solapamiento léxico, vocabulario específico, consultas ambiguas y fallas del etiquetado POS/lematización. El archivo de auditoría debe completarse con observaciones específicas antes de entregar el análisis de errores como final.

6. Reproducibilidad y limitaciones

Flujo: **python main.py vectorize** → revisar annotation_audit.tsv y qrels.tsv → **python main.py benchmark --approve** → **python main.py benchmark --all** → **python main.py report**. La colección original se conserva: no ejecutar merge después de congelar el benchmark sin volver a revisar los identificadores.

Limitaciones: las consultas difíciles pueden tener pocos términos compartidos con las reseñas; bigramas exactos suelen dar vectores de consulta vacíos y los lemas de jerga pueden ser ruidosos. El rendimiento reportado sobre los juicios usados para elegir la configuración no es una estimación independiente de generalización.